UNIVERSIDADE FEDERAL DE UBERLÂNDIA
FACULDADE DE ENGENHARIA ELÉTRICA
CURSO DE ENGENHARIA DE CONTROLE E AUTOMAÇÃO

RODRIGO MIALICHI TRIBONI

REDES BAYESIANAS E UTILIDADE ESPERADA APLICADAS À SELEÇÃO DE NEXT BEST ACTION EM SISTEMAS AUTOMATIZADOS DE DECISÃO

Projeto de Trabalho de Conclusão de Curso apresentado ao Curso de Engenharia de Controle e Automação da Universidade Federal de Uberlândia – UFU, Câmpus Santa Mônica, como requisito parcial para a

matrícula no componente curricular de Trabalho de Conclusão de Curso.

Orientador: Prof. Dr. [Nome do Orientador]

UBERLÂNDIA
2026

RESUMO

Sistemas de decisão automatizada, como motores de concessão de crédito, tradicionalmente separam de forma implícita a estimação de risco da escolha da ação a ser tomada, incorporando ambas em regras determinísticas ou escores ponderados de difícil auditoria. Este projeto propõe formalizar essas duas etapas como componentes distintos de um mesmo sistema de apoio à decisão: uma camada probabilística, baseada em redes bayesianas, responsável por estimar o risco de um caso a partir de evidências observadas; e uma camada de decisão, baseada em utilidade esperada, responsável por selecionar a próxima melhor ação (next best action) dentre um conjunto de alternativas admissíveis, a partir de uma função de utilidade que pondera custos, benefícios e restrições associados a cada combinação de ação e resultado. Será conduzida uma revisão bibliográfica sobre redes bayesianas, decisão sob incerteza e influence diagrams, seguida da modelagem e calibração de uma rede bayesiana de risco a partir do dataset público German Credit Data, da definição de uma função de utilidade demonstrativa e da implementação de um mecanismo de seleção de ações por utilidade esperada. O modelo será avaliado separadamente quanto ao desempenho preditivo (discriminação e calibração probabilística) e quanto ao desempenho da política de decisão, comparando-a a um baseline de regressão logística e a regras de limiar. Espera-se, como resultado, evidenciar que uma política de decisão fundamentada em inferência bayesiana calibrada e utilidade esperada explícita produz recomendações mais consistentes e transparentes do que abordagens baseadas apenas em limiares de escore.

Palavras-chave: Redes Bayesianas. Sistemas de Decisão. Next Best Action. Inteligência Artificial. Automação de Decisão.

SUMÁRIO

1 INTRODUÇÃO5
1.1 Justificativa6
1.2 Objetivos6
2 REVISÃO BIBLIOGRÁFICA8
2.1 Redes Bayesianas e Modelos Gráficos Probabilísticos8
2.2 Decisão sob Incerteza e Influence Diagrams8
2.3 Sistemas de Next Best Action e Credit Scoring9
3 METODOLOGIA10
4 CRONOGRAMA12
5 RECURSOS NECESSÁRIOS13
REFERÊNCIAS BIBLIOGRÁFICAS14

1 INTRODUÇÃO

A automação de processos de decisão é um dos pilares centrais da aplicação de inteligência artificial a sistemas de negócio, estando presente em domínios tão diversos quanto concessão de crédito, triagem de atendimento, manutenção preditiva e gestão de risco operacional. Historicamente, motores de decisão automatizados são construídos a partir de regras determinísticas e escores ponderados, nos quais critérios de negócio recebem pesos fixos definidos por especialistas de domínio. Essa abordagem, embora auditável, apresenta uma limitação estrutural pouco discutida: ela mistura, em uma única regra, a estimação de risco do caso e a escolha de qual ação tomar diante desse risco, sem tornar explícita a fronteira entre essas duas tarefas.

Redes bayesianas constituem uma classe de modelos gráficos probabilísticos capazes de representar explicitamente relações de dependência condicional entre variáveis aleatórias e de realizar inferência sob incerteza (PEARL, 1988). Aplicadas a um processo de decisão, redes bayesianas são naturalmente adequadas à primeira tarefa: estimar a probabilidade de um estado ou resultado (por exemplo, risco de inadimplência) a partir de evidências observadas. Entretanto, a probabilidade estimada não é, por si só, uma ação recomendada — a ação de maior probabilidade de sucesso não é necessariamente a ação de maior valor esperado para o negócio, uma vez que diferentes ações carregam diferentes custos, benefícios e restrições. Transformar uma estimativa de risco em uma recomendação de próxima melhor ação (next best action) exige, portanto, uma camada adicional de decisão, fundamentada em teoria da utilidade esperada, que os modelos puramente preditivos não fornecem por construção (JENSEN; NIELSEN, 2007).

Este projeto propõe investigar essa separação explícita entre inferência e decisão, estruturando o sistema proposto em três componentes: (i) uma rede bayesiana que estima a probabilidade de risco a partir de evidências; (ii) um conjunto de ações admissíveis, definidas para fins metodológicos e não como política real de concessão de crédito; e (iii) uma função de utilidade esperada que ordena essas ações e seleciona a recomendação de maior valor esperado. O estudo de caso adotado é o dataset público German Credit Data, utilizado exclusivamente para a modelagem da camada de risco — uma vez que o dataset não contém observações históricas de ações nem seus resultados contrafactuais, a avaliação da camada de decisão será

tratada explicitamente como uma simulação metodológica, e não como validação de uma política real.

1.1 Justificativa

A escolha do tema justifica-se, em primeiro lugar, pela sua aderência direta aos fundamentos do curso de Engenharia de Controle e Automação, notadamente aos conteúdos de sistemas de decisão sob incerteza, modelagem probabilística e automação de processos de decisão, ampliados pela incorporação de técnicas de inteligência artificial e teoria da decisão. Tratar o motor de decisão como uma camada supervisória de apoio à decisão, na qual a rede bayesiana estima um estado de risco não diretamente observável e um decisor separado escolhe a ação a partir da utilidade esperada, evidencia a convergência entre estimação sob incerteza — tema central da automação — e automação de decisões de negócio, sem equiparar indevidamente essa arquitetura a uma malha de controle dinâmico clássica, já que não há realimentação física nem variável controlada no sentido estrito do termo.

Em segundo lugar, o tema tem relevância prática imediata: sistemas de decisão que tratam risco e ação como a mesma etapa tendem a ocultar o critério real por trás de cada recomendação, dificultando auditoria e justificativa das decisões. Explicitar a função de utilidade torna o motor de decisão mais transparente e permite analisar sua sensibilidade a mudanças de critério de negócio. Por fim, o autor deste projeto atua profissionalmente no desenvolvimento de plataformas de automação e inteligência artificial aplicadas a processos de decisão de negócio, incluindo motores de crédito baseados em regras e escores ponderados, o que oferece familiaridade prática com os problemas de auditabilidade e opacidade que a separação entre inferência e decisão busca endereçar — sem que isso implique o uso de dados ou sistemas proprietários de qualquer organização específica, uma vez que o trabalho utiliza exclusivamente o dataset público German Credit Data.

1.2 Objetivos

O objetivo geral deste trabalho é desenvolver e avaliar um sistema probabilístico de apoio à decisão baseado em rede bayesiana, capaz de estimar risco sob incerteza e selecionar uma próxima melhor ação por meio de uma política explícita de utilidade esperada, utilizando o dataset público German Credit Data como estudo de caso.

São objetivos específicos:

- Realizar revisão bibliográfica sobre redes bayesianas, decisão sob incerteza, influence diagrams e sistemas de next best action;
- Modelar e calibrar a probabilidade do desfecho de crédito a partir das evidências disponíveis no German Credit Data;
- Comparar diferentes estratégias de definição da estrutura da rede bayesiana (orientada por conhecimento de domínio e/ou aprendida a partir dos dados);
- Comparar a qualidade preditiva da rede bayesiana com um baseline de regressão logística/scorecard;
- Definir um conjunto demonstrativo de ações admissíveis e uma função de utilidade documentada, com custos e benefícios explícitos;
- Implementar um mecanismo de seleção e ordenação de ações por utilidade esperada (next best action);
- Avaliar separadamente o desempenho preditivo do modelo de risco e o desempenho da política de decisão, incluindo análise de sensibilidade das utilidades adotadas;
- Implementar um protótipo simples e reprodutível que demonstre o fluxo completo: evidências, risco estimado, ação recomendada e justificativa.

2 REVISÃO BIBLIOGRÁFICA

Nesta seção são apresentados os principais conceitos e trabalhos que fundamentam o desenvolvimento proposto, abrangendo redes bayesianas e modelos gráficos probabilísticos, decisão sob incerteza e influence diagrams, e sistemas de next best action.

2.1 Redes Bayesianas e Modelos Gráficos Probabilísticos

Redes bayesianas são modelos gráficos probabilísticos que representam um conjunto de variáveis aleatórias e suas dependências condicionais por meio de um grafo acíclico dirigido, cujos nós correspondem a variáveis e cujas arestas representam relações de dependência direta, quantificadas por tabelas de probabilidade condicional (PEARL, 1988). Essa estrutura permite realizar inferência exata ou aproximada sobre a distribuição de probabilidade conjunta das variáveis, mesmo quando parte da evidência é parcial ou ruidosa, o que torna o formalismo especialmente adequado a problemas de tomada de decisão sob incerteza (KOLLER; FRIEDMAN, 2009).

Do ponto de vista de aprendizado de modelo, a construção de uma rede bayesiana envolve duas etapas: a definição da estrutura do grafo, que pode ser especificada por conhecimento de domínio ou aprendida a partir de dados por algoritmos de busca estrutural sujeitos a critérios como BIC ou BDeu, e a estimação dos parâmetros das distribuições condicionais, tipicamente por máxima verossimilhança ou por métodos bayesianos com distribuições a priori que suavizam contagens pequenas. Russell e Norvig (2010) discutem essas etapas no contexto mais amplo de sistemas de inteligência artificial baseados em raciocínio probabilístico, situando as redes bayesianas como uma das principais ferramentas de representação de conhecimento incerto em sistemas inteligentes.

2.2 Decisão sob Incerteza e Influence Diagrams

Estimar a probabilidade de um estado não é, por si só, suficiente para recomendar uma ação: é necessário um critério que traduza probabilidade em valor. A teoria da decisão sob incerteza formaliza esse critério por meio do conceito de utilidade esperada, segundo o qual a ação racional é aquela que maximiza $EU(a|x) = \Sigma\, P(y|a,x)\cdot U(a,y)$, em que x são as evidências observadas, a é uma ação candidata, y é um resultado possível e U(a,y) é a utilidade atribuída à combinação entre ação e resultado (RUSSELL; NORVIG, 2010). Influence diagrams (ou redes de decisão) estendem as redes bayesianas incorporando explicitamente nós de decisão e nós de

utilidade, além dos nós de chance tradicionais, permitindo representar em um único grafo tanto a incerteza sobre o estado do sistema quanto o processo de escolha da ação ótima (HOWARD; MATHESON, 2005; JENSEN; NIELSEN, 2007).

Essa distinção é central para este trabalho: um modelo que apenas classifica risco responde à pergunta "qual a probabilidade deste caso ser de alto risco?", mas não à pergunta "qual ação deve ser tomada?". A segunda pergunta exige a definição explícita de ações admissíveis e de uma função de utilidade, sem as quais qualquer recomendação de ação corre o risco de confundir maior probabilidade de sucesso com maior valor esperado para o negócio — que podem divergir sempre que ações diferentes carregam custos ou benefícios distintos (JENSEN; NIELSEN, 2007).

2.3 Sistemas de Next Best Action e Credit Scoring

Modelos de escore (scoring), amplamente utilizados em domínios como concessão de crédito, triagem de risco e priorização de atendimento, constituem a abordagem clássica para automação de decisões de negócio, atribuindo pesos a variáveis preditoras a partir de técnicas estatísticas como regressão logística, sendo adotados pela indústria em razão de sua interpretabilidade e simplicidade de auditoria (THOMAS, 2000; SIDDIQI, 2012). Entretanto, essas abordagens tratam a decisão essencialmente como uma classificação binária entre aprovar e negar (ou aceitar e rejeitar), aplicando um limiar sobre o escore sem tornar explícita a função de utilidade subjacente a esse limiar.

O conceito de next best action, originado na literatura de marketing analítico e sistemas de recomendação, propõe estruturar a decisão como a seleção da ação, dentre um conjunto de ações possíveis, que maximiza uma métrica de valor esperado dadas as características do caso analisado. Datasets de crédito consolidados na literatura, como o German Credit Data, fornecem tipicamente apenas um desfecho de risco binário (bom ou mau pagador), e não observações históricas de múltiplas ações com seus respectivos resultados; portanto, sistemas de next best action construídos sobre esses dados não podem aprender uma política de ação de forma supervisionada, sendo necessário compor a estimativa de risco com uma camada de decisão definida explicitamente pelo projetista, conforme discutido na Seção 2.2.

3 METODOLOGIA

O desenvolvimento deste trabalho seguirá uma abordagem estruturada em etapas sequenciais, com protocolo de validação definido antes do treinamento de qualquer modelo, de forma a evitar vazamento de informação entre as etapas de ajuste e de avaliação. As etapas estão descritas a seguir.

Etapa A – Formalização da Pergunta de Pesquisa e Protocolo Experimental

Formalização da pergunta de pesquisa central do trabalho — por exemplo: uma política de decisão baseada em probabilidades calibradas de uma rede bayesiana e em utilidade esperada produz decisões mais consistentes do que uma política de escore/limiares no estudo de caso German Credit? Definição precisa do desfecho a ser modelado, de sua codificação e de sua prevalência na base, além do protocolo de validação a ser seguido (separação de conjunto de teste ou validação cruzada estratificada), estabelecido antes de qualquer etapa de ajuste de modelo.

Etapa B – Análise Exploratória e Pipeline de Pré-processamento

Análise exploratória do German Credit Data (distribuições, cardinalidade das variáveis categóricas, dependências, redundâncias e equilíbrio entre classes), com documentação de todas as transformações aplicadas. Construção do pipeline de pré-processamento, incluindo discretização de variáveis contínuas quando necessária à modelagem bayesiana, com o cuidado explícito de ajustar qualquer discretização ou seleção de estrutura apenas dentro do conjunto de treino de cada partição, evitando vazamento de informação para o conjunto de teste.

Etapa C – Baseline e Modelagem da Rede Bayesiana de Risco

Construção de um baseline de regressão logística/scorecard com probabilidades calibradas, servindo de referência preditiva robusta e defensável. Em paralelo, construção da rede bayesiana de risco: definição de uma estrutura inicial orientada por conhecimento de domínio, comparação com uma estrutura aprendida a partir dos dados por critérios como BIC ou BDeu, e estimação dos parâmetros das tabelas de probabilidade condicional com suavização/priores para reduzir o efeito de contagens pequenas em uma base de aproximadamente mil registros.

Etapa D – Camada de Decisão: Ações e Utilidade Esperada

Definição de um conjunto demonstrativo de ações admissíveis (por exemplo: aprovar; solicitar informação ou garantia adicional; encaminhar para análise manual; rejeitar), tratadas como demonstração metodológica e não como política real de concessão de crédito. Construção de uma matriz de utilidade/custo documentada e transparente, associando cada combinação de ação e resultado a um valor. Implementação do mecanismo de seleção de next best action por utilidade esperada, $EU(a|x) = \Sigma\ P(y|a,x) \cdot U(a,y)$, ordenando as ações candidatas e registrando a segunda melhor alternativa e a diferença de utilidade entre elas.

Etapa E – Validação, Sensibilidade e Robustez

Avaliação separada de duas dimensões do sistema: desempenho preditivo do modelo de risco (ROC-AUC, PR-AUC quando pertinente, Brier score, log loss e diagrama de calibração) e desempenho da política de decisão (utilidade esperada média, custo esperado e distribuição das ações recomendadas), comparando a política bayeisana à política derivada do baseline por regras de limiar. Execução de análise de sensibilidade da matriz de utilidade, verificando se pequenas alterações nos custos e benefícios adotados alteram a recomendação, e teste de robustez do modelo frente a evidências incompletas, explorando a vantagem da inferência probabilística de operar com informação parcial.

Etapa F – Implementação do Protótipo e Explicabilidade

Implementação de um protótipo simples (por exemplo, em Streamlit) que demonstre o fluxo completo do sistema: entrada das evidências do caso, probabilidade de risco estimada, ranking de ações por utilidade esperada e justificativa da recomendação, incluindo as evidências mais relevantes e a variação em relação à probabilidade a priori. A interface é tratada como demonstração final do trabalho, e não como parte central da contribuição metodológica, sendo desenvolvida somente após a validação da metodologia estar concluída.

Etapa G – Redação do Trabalho Final

Redação contínua da monografia ao longo do semestre, com consolidação incremental dos resultados obtidos em cada etapa, discussão crítica das limitações do modelo e da avaliação, e organização final do texto conforme as normas da instituição.

Etapa H – Revisão Final e Preparação para Apresentação

Revisão final do texto e dos resultados, garantia de reprodutibilidade (fixação de sementes aleatórias, registro de versões de bibliotecas, disponibilização de notebook/script de preparação de dados, pipeline de treino e configuração experimental) e preparação da apresentação para a banca examinadora.

4 CRONOGRAMA

O desenvolvimento do trabalho será realizado ao longo do semestre letivo 2026/2, com início em setembro de 2026 e finalização em dezembro de 2026, conforme distribuição das etapas apresentada na Tabela 1.

Tabela 1 – Distribuição das etapas propostas.

Etapa	SET2026	OUT2026	NOV2026	DEZ2026
A – Pergunta, revisão e protocolo	X	X		
B – EDA e pipeline de pré-proc.	X	X		
C – Baseline e rede bayesiana		X	X	
D – Camada de decisão/NBA		X	X	
E – Validação e sensibilidade			X	X
F – Interface/protótipo			X	
G – Redação	X	X	X	X
H – Revisão final e apresentação				X

Fonte: Autoria própria.

5 RECURSOS NECESSÁRIOS

Para o desenvolvimento deste projeto, serão necessários os seguintes recursos:

- Um computador pessoal com capacidade de processamento adequada para treinamento de modelos probabilísticos;
- Ambiente de desenvolvimento Python, com bibliotecas de modelagem de redes bayesianas (por exemplo, pgmpy ou bibliotecas equivalentes com suporte a influence diagrams), de regressão logística e avaliação estatística (scikit-learn, pandas, numpy) e, para o protótipo final, uma biblioteca de interface simples (por exemplo, Streamlit);
- Dataset público German Credit Data (Statlog), disponível no repositório UCI Machine Learning Repository, sem dependência de dados proprietários de qualquer organização específica;
- Acesso à literatura científica especializada, por meio do portal de periódicos CAPES e das bases de dados disponibilizadas pelo Sistema de Bibliotecas da UFU;
- Acompanhamento periódico do professor orientador para validação técnica das etapas de modelagem e avaliação do modelo.

Todos os recursos computacionais necessários já se encontram disponíveis ao autor, não havendo necessidade de aquisição de equipamentos ou softwares adicionais para a execução deste projeto.

REFERÊNCIAS BIBLIOGRÁFICAS

BRIER, G. W. Verification of forecasts expressed in terms of probability. Monthly Weather Review, v. 78, n. 1, p. 1–3, 1950.

HOFMANN, H. Statlog (German Credit Data) Data Set. UCI Machine Learning Repository, 1994. Disponível em: https://archive.ics.uci.edu/ml/datasets/statlog+(german+credit+data).

HOWARD, R. A.; MATHESON, J. E. Influence diagrams. Decision Analysis, v. 2, n. 3, p. 127–143, 2005 (reimpressão do trabalho original de 1984).

JENSEN, F. V.; NIELSEN, T. D. Bayesian Networks and Decision Graphs. 2. ed. New York: Springer, 2007.

KOLLER, D.; FRIEDMAN, N. Probabilistic Graphical Models: Principles and Techniques. Cambridge: MIT Press, 2009.

PEARL, J. Probabilistic Reasoning in Intelligent Systems: Networks of Plausible Inference. San Francisco: Morgan Kaufmann, 1988.

RUSSELL, S.; NORVIG, P. Inteligência Artificial. 3. ed. Rio de Janeiro: Elsevier, 2010.

SIDDIQI, N. Credit Risk Scorecards: Developing and Implementing Intelligent Credit Scoring. 2. ed. Hoboken: John Wiley & Sons, 2012.

THOMAS, L. C. A survey of credit and behavioural scoring: forecasting financial risk of lending to consumers. International Journal of Forecasting, v. 16, n. 2, p. 149–172, 2000.